

Семинарска работа по предметот Бизнис статистика

Изработила: Драгана Трифунова 223044

ВОВЕД

Моето податочно множество „Customer Segmentation“ го избрав на Kaggle и до него можете да пристапите на следниот линк:

<https://www.kaggle.com/datasets/joebeachcapital/customer-segmentation?fbclid=IwAR1pocNYC4fRQG8mmGZTRGJRKP8kDuCUoFzlsDEVw74yM1hPYS3sYsHoKU>

Во ова множество имаме вкупно 5 најразлични податоци. ИД на потрошувачите, пол, години, годишен приход и поени од купување. Од нив за обработка ги избрав годините и поените на купувачите.

Обемот на податочното множество е 200 лица и се користи за да добиеме подобра визуелизација на потрошувачите. (колку трошат, како трошат, дали нивното трошење зависи од нешто друго и сл.)


1.A

Табела со распределба на честоти за години:


age.cu t	Fre q	midpo ints	age.c ut.1	Fre q.1	cum.f req	rel.cum. freq	rel.cum.f req2	age.c ut.2	Fre q.2	procent.cu m.freq
[18,21.5)	22	19.735	[18,21.5)	0.110	22	0.110	0.110	[18,21.5)	11.0	11.0
[21.5,24.9)	13	23.205	[21.5,24.9)	0.065	35	0.175	0.175	[21.5,24.9)	6.5	17.5
[24.9,28.4)	15	26.675	[24.9,28.4)	0.075	50	0.250	0.250	[24.9,28.4)	7.5	25.0
[28.4,31.9)	20	30.145	[28.4,31.9)	0.100	70	0.350	0.350	[28.4,31.9)	10.0	35.0
[31.9,35.4)	28	33.615	[31.9,35.4)	0.140	98	0.490	0.490	[31.9,35.4)	14.0	49.0
[35.4,38.8)	15	37.085	[35.4,38.8)	0.075	113	0.565	0.565	[35.4,38.8)	7.5	56.5
[38.8,42.3)	13	40.555	[38.8,42.3)	0.065	126	0.630	0.630	[38.8,42.3)	6.5	63.0
[42.3,45.8)	8	44.025	[42.3,45.8)	0.040	134	0.670	0.670	[42.3,45.8)	4.0	67.0
[45.8,49.2)	21	47.495	[45.8,49.2)	0.105	155	0.775	0.775	[45.8,49.2)	10.5	77.5
[49.2,52.7)	9	50.965	[49.2,52.7)	0.045	164	0.820	0.820	[49.2,52.7)	4.5	82.0
[52.7,56.2)	8	54.435	[52.7,56.2)	0.040	172	0.860	0.860	[52.7,56.2)	4.0	86.0
[56.2,59.6)	8	57.905	[56.2,59.6)	0.040	180	0.900	0.900	[56.2,59.6)	4.0	90.0
[59.6,63.1)	5	61.375	[59.6,63.1)	0.025	185	0.925	0.925	[59.6,63.1)	2.5	92.5

[18,21.5)	22	19.735	[18,21.5)	0.110	22	0.110	0.110	[18,21.5)	11.0	11.0
)			1)					1)		
[63.1,66.6)	5	64.845	[63.1,66.6)	0.025	190	0.950	0.950	[63.1,66.6)	2.5	95.0
[66.6,70)	10	68.315	[66.6,70)	0.050	200	1.000	1.000	[66.6,70)	5.0	100.0

Хистограм за годините на купувачите:



Полигон за годините на купувачите:




Табела со распределба на честоти за поените на купувачите:

score.cut	Fre q	midpo ints	score. cut.1	Fre q.1	cum.f req	rel.cum. freq	rel.cum.f req2	score. cut.2	Fre q.2	procent.cu m.freq
[1,7.54)	12	4.27	[1,7.54)	0.060	12	0.060	0.060	[1,7.54)	6.0	6.0
[7.54,14.1)	13	10.81	[7.54,14.1)	0.065	25	0.125	0.125	[7.54,14.1)	6.5	12.5
[14.1,20.6)	11	17.35	[14.1,20.6)	0.055	36	0.180	0.180	[14.1,20.6)	5.5	18.0
[20.6,27.2)	6	23.89	[20.6,27.2)	0.030	42	0.210	0.210	[20.6,27.2)	3.0	21.0
[27.2,33.7)	7	30.43	[27.2,33.7)	0.035	49	0.245	0.245	[27.2,33.7)	3.5	24.5
[33.7,40.2)	14	36.97	[33.7,40.2)	0.070	63	0.315	0.315	[33.7,40.2)	7.0	31.5
[40.2,46.8)	23	43.51	[40.2,46.8)	0.115	86	0.430	0.430	[40.2,46.8)	11.5	43.0
[46.8,53.3)	26	50.05	[46.8,53.3)	0.130	112	0.560	0.560	[46.8,53.3)	13.0	56.0
[53.3,59.9)	23	56.59	[53.3,59.9)	0.115	135	0.675	0.675	[53.3,59.9)	11.5	67.5
[59.9,66.4)	8	63.13	[59.9,66.4)	0.040	143	0.715	0.715	[59.9,66.4)	4.0	71.5
[66.4,72.9)	6	69.67	[66.4,72.9)	0.030	149	0.745	0.745	[66.4,72.9)	3.0	74.5
[72.9,79.5)	21	76.21	[72.9,79.5)	0.105	170	0.850	0.850	[72.9,79.5)	10.5	85.0
[79.5,86)	8	82.75	[79.5,86)	0.040	178	0.890	0.890	[79.5,86)	4.0	89.0


[1,7.54)	12	4.27	[1,7.54)	0.060	12	0.060	0.060	[1,7.54)	6.0	6.0
[86,92.6)	13	89.29	[86,92.6)	0.065	191	0.955	0.955	[86,92.6)	6.5	95.5
[92.6,99.1)	9	95.83	[92.6,99.1)	0.045	200	1.000	1.000	[92.6,99.1)	4.5	100.0

Хистограм за поените на купувачите:



Полигон за поените на купувачите:

Полигон за поените на купувачите



```
#tabela so raspredelba na cestoti za age
n_age=length(Mall_Spending$Age)
sort(Mall_Spending$Age)
range(Mall_Spending$Age)
max(Mall_Spending$Age, na.rm = TRUE)-min(Mall_Spending$Age, na.rm=TRUE)
breaks_age=seq(18, 70.05, by=3.47)
breaks_age
age.cut=cut(Mall_Spending$Age, breaks_age, right=FALSE)
age_freq=table(age.cut)
age_rel.freq=age_freq/n
age_cum.freq=cumsum(age_freq)
age_rel.cum.freq=cumsum(age_freq)/n
age_rel.cum.freq2=cumsum(age_rel.freq)
age_procent.freq=age_rel.freq*100
age_procent.cum.freq=age_rel.cum.freq*100
midpoints_age<-(breaks_age[-1]+breaks_age[-length(breaks_age)])/2
#final_table <- data.frame(freq, midpoints, rel.freq, cum.freq, rel.cum.freq, rel.cum.freq2,
procent.freq, procent.cum.freq)

final_table_age <-data.frame(age_freq, midpoints_age, age_rel.freq, age_cum.freq,
age_rel.cum.freq, age_rel.cum.freq2, age_procent.freq, age_procent.cum.freq)

#histogram age
hist(Mall_Spending$Age, right = FALSE, col=colors, main="Возраст на купувачите",
xlab="интервали", ylab="честоти")

#poligon
d_age=density(Mall_Spending$Age)
```

```
plot(d_age, main="Полигон за возраста на купувачите", xlab="интервали", ylab="густина")
polygon(d_age, col="skyblue")
```

```
#tabela so raspredelba na cestoti za kupuvacite
n=length(Mall_Spending$Spending.Score..1.100.)
sort(Mall_Spending$Spending.Score..1.100.)
range(Mall_Spending$Age)
range(Mall_Spending$Spending.Score..1.100.)
max(Mall_Spending$Spending.Score..1.100., na.rm = TRUE)-
min(Mall_Spending$Spending.Score..1.100., na.rm=TRUE)
#ja odreduvam sirinata na intervalot
#w >= R/k --> w >= 98/15
sirina_interval_poeni<-98/15
sirina_interval_poeni <- 98/15
sirina_interval_poeni
breaks=seq(1, 99, by=6.54)
breaks
score<-Mall_Spending$Spending.Score..1.100.
score.cut=cut(Mall_Spending$Spending.Score..1.100., breaks, right=FALSE)
freq=table(score.cut)
rel.freq=freq/n
cum.freq=cumsum(freq)
rel.cum.freq=cumsum(freq)/n
rel.cum.freq2=cumsum(rel.freq)
procent.freq=rel.freq*100
procent.cum.freq=rel.cum.freq*100
midpoints<-(breaks[-1]+breaks[-length(breaks)])/2
final_table <- data.frame(freq, midpoints, rel.freq, cum.freq, rel.cum.freq, rel.cum.freq2,
procent.freq, procent.cum.freq)
final_table
breaks
#2 obid za podobar interval
breaks=seq(1, 99.1, by=6.54)
breaks
score<-Mall_Spending$Spending.Score..1.100.
score.cut=cut(Mall_Spending$Spending.Score..1.100., breaks, right=FALSE)
freq=table(score.cut)
rel.freq=freq/n
cum.freq=cumsum(freq)
rel.cum.freq=cumsum(freq)/n
rel.cum.freq2=cumsum(rel.freq)
procent.freq=rel.freq*100
procent.cum.freq=rel.cum.freq*100
midpoints<-(breaks[-1]+breaks[-length(breaks)])/2
final_table <- data.frame(freq, midpoints, rel.freq, cum.freq, rel.cum.freq, rel.cum.freq2,
```

```

procent.freq, procent.cum.freq)
#kreiranje na histogram za score
colors<-col(c("red", "white", "yellow", "blue", "purple", "lightblue", "pink", "green", "black",
"orange"))
colors=c("red", "blue", "orange", "purple", "pink", "lightblue", "black", "white", "green")
hist(Mall_Spending$Spending.Score..1.100., right=FALSE, col=colors, main="Поени на
купувачите", xlab="поени", ylab="кумулятивна честота")
#kreiranje poligon za poeni na kupuvacite
d=density(Mall_Spending$Spending.Score..1.100.)
plot(d, main="Полигон за поените на купувачите", xlab="поени", ylab="густина")
polygon(d, col="pink")

```

2.A

Стебло лист дијаграм за годините:

```

1 | 888899999999
2 | 0000011111222333334444
2 | 55566777777888899999
3 | 000000011111111222222222233344444
3 | 5555555556666666777888888999
4 | 000000112233344
4 | 555666777777888889999999
5 | 000001122334444
5 | 5677889999
6 | 000334
6 | 556677778889
7 | 00

```

Стебло лист дијаграм за поените за купувачите:

```

0 | 11344
0 | 555566789
1 | 00123334444
1 | 555667778
2 | 00234
2 | 6678899
3 | 1224
3 | 555556699
4 | 00001111222222223334
4 | 5666666777788888999
5 | 00000111222223444

```

```
5 | 55555556666778899999
6 | 000113
6 | 56899
7 | 12233333344
7 | 5555566777899
8 | 11233
8 | 566778889
9 | 0011222334
9 | 557789
```


```
#steblo list za godini
steblo_list_godini <-stem(Mall_Spending$Age)
  steblo_list_godini
#steblo list za poeni
stem(Mall_Spending$Spending.Score..1.100.)
```

3. A

График на расејување за податоците години и поени на потрошувачите

```
#grafik na rasejuvanjne
library(tidyverse)
plot(x=Mall_Spending$Age, y=Mall_Spending$Spending.Score..1.100., main="Години на
  потрошувачите наспроти поени на потрошувачите", xlab="Години на
  потрошувачите", ylab="Поени на потрошувачите")
```


Години на потрошувачите наспроти поени на потрошувачите



Според графикот, годините и поените на потрошувачите немаат линеарна или крива поврзаност.

Од сликата можам да забележам дека коефициентот на корелација се движи околу (-0.3, 0.3) затоа што точките не се воопшто поврзани. (Дури не можеме да забележиме дали правата се движи негативно или позитивно)

4. А

Мода, медијана и просек на податоците

Просекот на годините на купувачите изнесува 38.85 а, на поените на купувачите 50.2.

Медијаната на годините на купувачите е 36, додека на поените на купувачите е 50.

Во R Studio нема посебна функција за мода (доколку не вклучуваме одредени библиотеки) па, затоа јас формирав своја функција:

```
mode<-function(x){  
  unique_val <- unique(x)  
  counts<-vector()  
  for(i in 1 :length(unique_val))  
  {  
    counts[i]<-length(which(x==unique_val[i]))  
  }  
  position<-c(which(counts==max(counts)))  
  if(length(unique_val)==length(x))
```

```

mode_x <- 'Mode does not exist'
else
mode_x <-unique_val[position]
return (mode_x)
}

```

Модата на годините на купувачите изнесува 32, додека пак модата на поените 42.

```

#prosek na age, score
mean(Mall_Spending$Age)
mean(Mall_Spending$Spending.Score..1.100.)
#medijana na age, score
medijana_age <- median(Mall_Spending$Age)
medijana_age
medijana_score <- median(Mall_Spending$Spending.Score..1.100.)
medijana_score
#posebna funkcija za naoganje na modata
mode<-function(x){
unique_val <- unique(x)
counts<-vector()
for(i in 1 :length(unique_val))
{
counts[i]<-length(which(x==unique_val[i]))
}
position<-c(which(counts==max(counts)))
if(length(unique_val)==length(x))
mode_x <- 'Mode does not exist'
else
mode_x <-unique_val[position]
return (mode_x)
}
mode(Mall_Spending$Age)
mode(Mall_Spending$Spending.Score..1.100.)

```

5.A

Квартали, опсег и интерквартален распон

Квартали за годините на купувачите:

1 квартал	28.75
2 квартал	36
3 квартал	49

Квартали за поените на купувачите:

1 квартал 34.75

2 квартал 50

3 квартал 73

Опсегот на годините е 52, а на поените на купувачите е 98.

Интерквартален распон за годините 20.25 додека пак за поените на купувачите е 38.25

```
#kvartali, opseg i interkvartalen raspon godini
prv_kvartal_age<-quantile(Mall_Spending$Age, 0.25)
vtor_kvartal_age<-quantile(Mall_Spending$Age, 0.50)
tret_kvartal_age<-quantile(Mall_Spending$Age, 0.75)
prv_kvartal_age
vtor_kvartal_age
tret_kvartal_age
#kvartali score
kvartali_score <- quantile(Mall_Spending$Spending.Score..1.100.)
kvartali_score
#opseg na score
max(Mall_Spending$Spending.Score..1.100., na.rm=TRUE)-
min(Mall_Spending$Spending.Score..1.100., na.rm=TRUE)
opseg_score<-max(Mall_Spending$Spending.Score..1.100., na.rm=TRUE)-
min(Mall_Spending$Spending.Score..1.100., na.rm=TRUE)
opseg_score
#opseg godini
opseg_godini<-max(Mall_Spending$Age, na.rm=TRUE)-min(Mall_Spending$Age,
na.rm=TRUE)
opseg_godini
#IQR godini
interkvartalen_godini=IQR(Mall_Spending$Age)
interkvartalen_godini
#IQR score
interkvartalen_score=IQR(Mall_Spending$Spending.Score..1.100.)
interkvartalen_score
```

6.A

Дисперзија и стандардна девијација

Стандардната девијација на годините е 13.96 додека, на поените е 25.82

Дисперзијата ја наоѓаме како стандардна девијација на квадрат односно, дисперзијата на годините изнесува 195.13 додека пак на поените изнесува 666.85

```
#disperzija i standardna devijacija
#age
standardna_devijacija_age=sd(Mall_Spending$Age)
standardna_devijacija_age
#disperzija age preku sd
disperzija_age=sd(Mall_Spending$Age)^2
disperzija_age
#standardna devijacija score
standardna_devijacija_score=sd(Mall_Spending$Spending.Score..1.100.)
standardna_devijacija_score
#disperzija score preku standardna devijacija
disperzija_score=sd(Mall_Spending$Spending.Score..1.100.)^2
disperzija_score
```

7. A

Коефициентот на корелација за годините и поените на купувачите изнесува -0.3272268 што значи дека се слабо линеарно поврзани со негативен правец на права.

```
#koeficient na korelacija za godinite i poenite na kupuvacite
cor(Mall_Spending$Age, Mall_Spending$Spending.Score..1.100.)
koeficient_korelacija=cor(Mall_Spending$Age, Mall_Spending$Spending.Score..1.100.)
koeficient_korelacija
```

1. Б

95% интервал на доверба за математичкото очекување на поените на купувачот
За оваа точка ни се потребни просекот, стандардната девијација и големината на примерокот и Z_{α_2} .

Спред R Studio:

просек=50.2

стандардна девијација=25.82352

n=200

$\Phi(Z_{\alpha_2})=1-0.05/2$

$Z_{\alpha_2}=1.959964$

Ја користиме формулата:

$$\left[\bar{X} - z_{\frac{\alpha}{2}} * \left(\frac{\sigma}{\sqrt{n}} \right) \right], \left[\bar{X} + z_{\frac{\alpha}{2}} * \left(\frac{\sigma}{\sqrt{n}} \right) \right]$$

Според пресметката направена во R Studio која ви ја исправив во source code, со 95% интервал на доверба можеме да кажеме дека математичкото очекување на поените се движи од (46.62111, 53.77889)

```
# 95% intervali na doverba za poenite na kupuvacot
error<-qnorm(0.975)*sd(Mall_Spending$Spending.Score..1.100.)/sqrt(length(Mall_Spending$
Spending.Score..1.100.))
error
#zet alfa pola
qnorm(0.975)
#prosek-error
pocetok_interval_doverba=mean(Mall_Spending$Spending.Score..1.100.)-error
#prosek+error
kraj_interval_dobverba=mean(Mall_Spending$Spending.Score..1.100.)+error
pocetok_interval_doverba
kraj_interval_dobverba
```

2. Б

Знаеме дека очекуваните поени на купувачот се 50,2 но, се сомневам дека очекуваните поени на купувачот се поголеми од 50,2.

Затоа земаме примерок од 10 случајно избрани купувачи од нашето обележје „поени на купувачот“ во податочното множество.

81, 44, 46, 77, 88, 97, 13, 17, 83, 49

Го наоѓаме просекот од примерокот кој изнесува 59,5.

Математичкото очекување (50,2) и стандардната девијација (25.82352) на обележјето се познати од претходните точки. Исто така $n > 30$ што значи дека ќе користиме Z статистика.

$$Z_0 = \left(\frac{\bar{x} - \mu_0}{\sigma} \right) * \sqrt{n}$$

Така што:

$H_0: \mu = 50,2$

$H_a: \mu > 50,2$

На крај, ја пресметуваме горенаведената формула и добиваме 5.093103.

Критичниот домен е $C(Z\alpha, +\infty)$.

Со ниво на значајност од 0.05 во R студио ја откриваме $Z\alpha$.

$Z\alpha = 1.644854$

$C(1.644854, +\infty)$

Z_0 припаѓа во критичниот домен $\rightarrow H_a$ се прифаќа, со ниво на значајност од 0.05 очекуваните поени на купувачот се поголеми од 50,2.

```

#testiranje na hipotezi
slucaen_primerok_score<-c(81, 44, 46, 77, 88, 97, 13, 17, 83, 49)
zet_statistika<-(mean(slucaen_primerok_score)-
mean(Mall_Spending$Spending.Score..1.100.))/sd(Mall_Spending$Spending.Score..1.100.)
zet_statistika
zet_statistika<-0.3601368*sqrt(length(Mall_Spending$Spending.Score..1.100.))
zet_statistika
#ja otkrivam zet alfa
#so nivo na znacajnost 0.05
qnorm(1-0.05)

```

3.Б

Тест за распределба

Ќе тестираме дали обележјето X:поени на купувачот има нормална распределба.
Поставуваме 2 хипотези.

H_0 : Поените на купувачот имаат нормална распределба

H_a : Поените на купувачот **НЕМААТ** нормална распределба

Shapiro-Wilk тестот се користи за да видиме дали гласовите имаат нормална распределба. Тој работи со 95% интервал на доверба.

```

#test za raspredelba na poenite na kupuvacot
shapiro.test(Mall_Spending$Spending.Score..1.100.)

```

Според R Studio добиваме:

Shapiro-Wilk normality test

```

data: Mall_Spending$Spending.Score..1.100.
W = 0.96946, p-value = 0.0002423

```

$p < 0.05$ ----> податоците немаат нормална распределба

4.Б

```

#testiranje hipotezi za nezavisnost
#testiranje hipotezi za nezavisnost
summary(table(Mall_Spending$Age, Mall_Spending$Spending.Score..1.100.))
x=Mall_Spending$Age
y=Mall_Spending$Spending.Score..1.100.
chisq.test(x, y)

```

Тестирање хипотези за независност

X – години на купувачот

Y – поени на купувачот

Треба да провериме дали годините на купувачите зависат од поените кои ги добиле.

За таа цел ние ќе употребиме „Пирсонов Хи квадрат тест“ на хипотезите:

H_0 : X и Y се независни обележја

H_a : X и Y се зависни обележја

Резултатот од Пирсоновиот тест е со ниво на значајност $\alpha=0.05$

Според овој тест кој го применивме во R Studio добивме p-value = 0.1954

Бидејќи $p > \alpha$ нултата хипотеза **не** се отфрла ---> Двете обележја се меѓусебно независни.

5. Б

```
#regresiona analiza
regresija=lm(Mall_Spending$Age ~ Mall_Spending$Spending.Score..1.100.)
newdata=data.frame(m=20)
regresija.res=resid(regresija)
plot(Mall_Spending$Spending.Score..1.100., regresija.res, main="Права на регресија на
годините во зависност од поените", xlab="возраст", ylab="поени", col="blue")
abline(regresija)
lm(formula=Mall_Spending$Age ~ Mall_Spending$Spending.Score..1.100.)
```

```
#naoganje koeficient na determinantnost
(cor(Mall_Spending$Age, Mall_Spending$Spending.Score..1.100.))**2
```

Да се определи правата на регресија на годините во зависност од поените на купувачите.

Тоа значи да се определи у преку x.

y – години на купувачот

x – поени на купувачот

Правата на регресија е $y=47.74 - 0.177x$

Со оваа права за било кои поени на купувачот ќе ги добиеме неговите години.

Исто така постои и права во која за било кои години на купувачот ќе се добијат неговите поени. Тоа е правата x преку y .

Коефициентот на детерминантност е: 0.1070774 што укажува на многу слаба врска помеѓу обележјата.

На сликата исто така се забележува слабата линеарна поврзаност.

